

真正理解 Transformer 的 QKV

为什么注意力需要三种角色表示

Q 和 K 学习从哪里取信息，V 承担实际传递的内容，三者共同把孤立词向量改写为有方向、可学习的上下文表示。

从对称相似度、方向性匹配到上下文表示



视频名称	Transformer 模型为何需要 QKV 三个矩阵？QKV 到底在计算什么？
作者/UP 主	人工智能研究所 _
发布时间	2026-07-04
视频时长	09:55
转录来源	Whisper small (faster-whisper CPU int8)，经自动建议与人工上下文复核修订
数据来源	视频元数据、修订后的 312 段时间线、8 张直接检查的关键画面
视频链接	https://www.bilibili.com/video/BV1uPMA62E8e

目录

1 核心问题：词向量为什么要互相看一眼	2
1.1 孤立向量缺少什么	2
1.2 从相互感知到动态表示	2
1.3 本章小结	3
2 错误直觉：为什么 $X X^T$ 的转置走不通	3
2.1 最直接的相似度方案	3
2.2 对称性与不可学习性	4
2.3 本章小结	4
3 QKV：三副可学习眼镜如何打破对称	4
3.1 同一个输入的三种角色	4
3.2 不同投影如何产生方向性	5
3.3 本章小结	6
4 两套直觉：图书馆类比与几何投影	6
4.1 图书馆：先匹配标签，再取走内容	6
4.2 几何：在两套子空间中隔空比较	7
4.3 本章小结	8
5 从匹配分数到新的上下文表示	8
5.1 缩放与 Softmax：把分数变成比例	8
5.2 为什么最后必须乘 V	9
5.3 本章小结	10
6 总结、常见误区与延伸练习	10
6.1 一条可复述的因果链	10
6.2 三个常见误区	11
6.3 自测与下一步	11

1 核心问题：词向量为什么要互相看一眼

■ 核心主线

注意力不是从 Q、K、V 三个字母开始的。它首先要解决一个更朴素的问题：初始词向量彼此孤立，只有让每个词按相关程度吸收上下文信息，句子中的角色和关系才会进入表示。¹

1.1 孤立向量缺少什么

词嵌入把 I、love、AI 分别变成向量，但这一步只给出了每个词自己的初始位置。AI 的向量并不知道旁边站着 I 和 love，love 也尚未知道谁是动作发出者、谁是动作对象。换句话说，初始向量有词义，却没有当前句子的关系。²




图 1: 三个初始词向量是孤立点；虚线提示它们需要通过上下文关系重新调整。³

1.2 从相互感知到动态表示

注意力机制让当前词先判断其他词与自己有多相关，再按相关程度吸收它们携带的信息。这样得到的新向量不再是词典式的固定坐标，而是针对当前句子临时生成的动态表示。同一个 love 出现在不同句子里，可以因为周围词不同而获得不同结果。⁴

¹ 来源时间: 00:01:23-00:01:34。

² 来源时间: 00:00:46-00:01:15。

³ 来源时间: 00:01:28-00:01:32。

⁴ 来源时间: 00:01:27-00:01:34, 00:09:02-00:09:12。

1.3 本章小结

先不要急着背公式：注意力的任务是把上下文写回词表示。只要一个词仍然是互不相知的孤立点，模型就还没有完成对句子结构的建模。⁵

2 错误直觉：为什么 $X X$ 的转置走不通

2.1 最直接的相似度方案

最自然的想法是把所有词向量按行堆成矩阵 X ，再计算 $X X$ 的转置。结果矩阵中的每个元素都是两个词向量的点积，可以理解为两词的原始相似度。这个方案计算简单，也确实给出了完整的两两匹配分数。⁶

直接相似度矩阵

$$S = X X^T, \quad S_{ij} = x_i \cdot x_j$$

- X ：按行堆叠的词向量矩阵
- S ：词与词的点积相似度矩阵

7

人工智能研究所_bilibili 为什么不能直接用 $X \cdot X^T$?

(I, love, AI 的词向量，每行一个词)

$$\begin{bmatrix} \text{I} & 1 & 0 \\ \text{love} & 0 & 1 \\ \text{AI} & 1 & 1 \end{bmatrix} \times X^T \Rightarrow \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 2 \end{bmatrix}$$

$X X^T$ (词与词的原始相似度)

(I love) 和 (love I) 永远相等 !

$$(X X^T)^T = X X^T$$

AI Powers

图 2: $X X$ 的转置必然得到对称矩阵，反向位置被迫取相同分数。⁸

⁵来源时间: 00:01:23–00:01:34。

⁶来源时间: 00:01:34–00:01:56。

⁷来源时间: 00:01:41–00:01:54。

⁸来源时间: 00:02:08–00:02:17。

2.2 对称性与不可学习性

点积具有交换性，因此第 i 个词对第 j 个词的分数必然等于反向分数。可语言关系通常有方向：作为动词，love 需要寻找主语 I 和对象 AI ；代词 I 却未必以同样程度依赖 love。对称矩阵把这种角色差异从结构上抹掉了。⁹

■ 两个死穴必须同时看到

直接使用 $X X$ 的转置不只会锁死方向，它还没有额外的可学习匹配参数。模型无法通过训练调整‘应该关注谁’，因此即使计算出了相似度，也不是足够灵活的注意力机制。¹⁰

2.3 本章小结

静态相似度不是注意力的终点。一个可用的方案必须让反向关系可以不同，还必须让匹配规则能通过数据学习；这正是引入 Q 、 K 、 V 三组投影的原因。¹¹

3 QKV：三副可学习眼镜如何打破对称

3.1 同一个输入的三种角色

视频把 W_Q 、 W_K 、 W_V 比作三副魔法眼镜。输入 X 经过三组不同、可学习的线性变换后，得到 Query、Key、Value。Query 表示‘我想寻找什么’，Key 表示‘我可以如何被匹配’，Value 表示‘匹配后我真正传递什么’。¹²

三组角色投影

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

- W_Q 、 W_K 、 W_V ：由训练学习的投影矩阵
- Q/K ：用于匹配， V ：用于内容汇聚

⁹来源时间：00:02:06–00:02:44。

¹⁰来源时间：00:02:45–00:02:56。

¹¹来源时间：00:02:53–00:03:07。

¹²来源时间：00:03:05–00:03:38。

¹³来源时间：00:03:11–00:03:26。




图 3: 同一个 I 经三组投影后形成 Q、K、V 三个不同分身。¹⁴

3.2 不同投影如何产生方向性

由于 W_Q 与 W_K 不同, 同一个词在提问角色和被匹配角色中的表示不同。于是 QK 的转置不再继承 $X X^T$ 转置的强制对称性: $\text{love} \rightarrow I$ 与 $I \rightarrow \text{love}$ 可以得到不同分数, 模型也能通过训练调整这种差异。¹⁵

¹⁴来源时间: 00:03:42–00:03:53。

¹⁵来源时间: 00:03:49–00:04:03。




图 4: 手算结果中反向位置不再相等, QK 的转置表达出方向性匹配。¹⁶

在二维示例里, love 关注 I 的分数高于 I 关注 love 的分数。这个数值只是教学用玩具结果, 但它准确展示了结构能力: 同一对词的两个方向不必相等, 注意力可以学习谁在当前关系中更需要谁。

¹⁷

3.3 本章小结

QKV 不是三个独立对象, 而是同一输入的三种可训练角色。Q/K 负责建立方向性匹配, V 保留待传递的内容; 角色分离同时带来了非对称性和可学习性。¹⁸

4 两套直觉：图书馆类比与几何投影

4.1 图书馆：先匹配标签，再取走内容

想找恐龙书的需求是 Query; 每本书的标签摘要是 Key; 真正的书中内容是 Value。你先用需求与标签比较, 找出高匹配书籍, 但最后带走的是内容而不是标签。这个类比把匹配通道与内容通道清楚分开。¹⁹

¹⁶来源时间: 00:04:11–00:04:38。

¹⁷来源时间: 00:04:04–00:04:49。

¹⁸来源时间: 00:04:47–00:05:04。

¹⁹来源时间: 00:05:11–00:05:55。




图 5: Query与书籍 Key 匹配，高分标签定位相关内容；真正传递的是 Value。²⁰

■ 不要混淆 Key 与 Value

Key 像可检索的标签，负责让内容被找到；Value 才是后续加权汇入输出的信息。如果把两者混为一谈，就无法解释为什么匹配分数最终还要乘 V 。²¹

4.2 几何：在两套子空间中隔空比较

几何视角把 W_Q 看作对原始空间的拉伸，把 W_K 看作另一种基变换。于是同一个词在 Query 空间和 Key 空间中的位置不同。匹配分数是两个不同空间表示之间的点积，反向比较交换了角色，自然不再要求结果相等。²²

²⁰来源时间：00:05:10–00:06:01。

²¹来源时间：00:05:21–00:06:01。

²²来源时间：00:06:34–00:07:34。




图 6: 原始、Query与 Key 三个空间并列展示；同一词在两套投影空间中的位置不同。²³

4.3 本章小结

图书馆类比回答 ‘Q/K/V分别做什么’，几何投影回答 ‘为什么 QK 的转置可以非对称’。能同时说清匹配、内容和方向性，才算真正跨过了只会背字母的阶段。²⁴

5 从匹配分数到新的上下文表示

5.1 缩放与 Softmax：把分数变成比例

QK的转置只产生原始匹配分数。视频接着把分数除以根号 d_k ，控制高维点积的幅度，再通过 Softmax 转换成非负且总和为 1 的权重。这样，抽象分数就变成了当前词对各位置分配的注意力比例。²⁵

缩放点积注意力的完整形式

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

- QK^T : 方向性匹配分数
- d_k : Key 的维度
- Softmax: 把分数归一化为权重

²³来源时间: 00:06:34–00:07:38。

²⁴来源时间: 00:05:55–00:06:04, 00:07:24–00:07:40。

²⁵来源时间: 00:07:48–00:08:27。

- V: 被权重汇聚的内容表示

26




图 7: love 的三个分数先缩放, 再经 Softmax 变成总和为 1 的注意力权重。²⁷

5.2 为什么最后必须乘 V

权重本身只说明该去哪里取信息, 仍不是新词表示。把每个权重乘到对应 Value 向量上并求和, 才得到当前词的输出。对 love 而言, 新向量混合了 I、love、AI 的内容, 因此它的位置和含义都被当前上下文重新塑造。²⁸

²⁶来源时间: 00:07:48–00:08:35。

²⁷来源时间: 00:07:48–00:08:27。

²⁸来源时间: 00:08:31–00:09:04。




图 8: 三个 Value 的加权和落在其三角形内部, 形成 love 的新上下文向量。²⁹

■ 几何上的凸组合

Softmax 权重非负且总和为 1, 因此加权结果位于 Value 向量的凸包中。视频的二维示例把它画成三角形内部的一个点, 直观展示输出如何由多个上下文来源共同组成。³⁰

5.3 本章小结

完整注意力不是一次矩阵乘法, 而是一条信息路由链: Q/K 计算方向性相关度, 缩放和 Softmax 形成稳定权重, V 的加权和把相关上下文写入当前词。³¹

6 总结、常见误区与延伸练习

6.1 一条可复述的因果链

从问题出发复述全片: 初始词向量缺少上下文; X X 的转置虽然能算相似度, 却对称且不可学习; W_Q 与 W_K 让提问和被匹配使用不同表示; 缩放与 Softmax 把 QK 的转置变成权重; 权重汇聚 V, 形成新的上下文表示。³²

²⁹来源时间: 00:08:31-00:09:00。

³⁰来源时间: 00:08:20-00:08:45。

³¹来源时间: 00:08:51-00:09:12。

³²来源时间: 00:09:19-00:09:44。

6.2 三个常见误区

- 误区一：Q、K、V 是三个不同的词。实际上它们是同一输入的三种角色投影。
- 误区二：Key 是最终取出的内容。实际上 Key 用于匹配，Value 才承载被汇聚的信息。
- 误区三：二维单头手算就是完整 Transformer。它只负责建立机制直觉，未覆盖多头、掩码、残差与高维实现。³³

6.3 自测与下一步

1. 不用公式解释：为什么 $\text{love} \rightarrow I$ 与 $I \rightarrow \text{love}$ 不应被强制相等？
2. 画出图书馆类比，分别标出 Query、Key、Value，并说明最后真正带走的是什么。
3. 从 QK 的转置开始，口述缩放、Softmax 和乘 V 的每一步职责。
4. 进一步学习多头注意力、掩码、残差连接，并比较它们与本视频单头玩具例子的边界。³⁴

■ 最后带走的一句话

Q和K学习‘从哪里取’，V承担‘实际取什么’；注意力用方向性权重把相关上下文写回每个词，使词义成为随句子变化的动态表示。³⁵

³³来源时间：00:00:38–00:00:40, 00:03:21–00:03:38, 00:05:49–00:06:23。

³⁴来源时间：00:02:16–00:02:44, 00:05:11–00:06:01, 00:07:48–00:08:35。

³⁵来源时间：00:06:14–00:06:23, 00:09:02–00:09:12。